

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



BÀI TẬP LỚN

NHẬP MÔN TRÍ TUỆ NHÂN TẠO

Đề tài: Trích xuất đặc trưng chuỗi URL, biểu diễn URL dưới dạng vector đặc trưng, áp dụng SMOTE cân bằng dữ liệu, triển khai Naive Bayes kết hợp so sánh Random Forest nâng cao độ chính xác và khả năng nhận diện URL

Giảng viên: PGS. TS. Lê Thanh Hương

Mã lớp: 168452

Nhóm:16

STT	Họ và tên	MSSV
1	Vũ Minh Hoàng	202416494
2	Ngô Đức Thắng	202400089
3	Vũ Minh Tú	202416379
4	Vũ Tiến Thành	202416610

MỤC LỤC

GIỚI THIỆU ĐỀ TÀI	6
CHƯƠNG 1. TỔNG QUAN HỆ THỐNG AI CYBER SHIELD	7
1.1. Giới thiệu hệ thống AI Cyber Shield	7
1.2. Giao diện tổng quan của hệ thống	7
1.3. Các chức năng chính của hệ thống	8
1.3.1. Scanner	8
1.3.2. Model	8
1.3.3. History	8
1.3.4. Feature	8
1.3.5. About	8
1.4. Quy trình hoạt động của hệ thống	8
1.5. Công nghệ và công cụ sử dụng	9
1.6. Kết luận chương	9
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	10
2.1. Tổng quan về URL phishing	10
2.2. Thuật toán Naive Bayes	10
2.3. Thuật toán Random Forest	11
2.4. Kỹ thuật SMOTE	11
CHƯƠNG 3. PHÂN TÍCH VÀ XÂY DỰNG HỆ THỐNG	13
3.1. Tập dữ liệu	13
3.2. Tiền xử lý dữ liệu	13
3.3. Trích xuất đặc trưng URL	13
3.3.1 Nhóm đặc trưng dựa trên cấu trúc URL	13
3.3.2 Nhóm đặc trưng liên quan đến domain và bảo mật	14
3.3.3 Nhóm đặc trưng dựa trên mã HTML và hành vi website	14
3.4. Biểu diễn URL dưới dạng vector đặc trưng	14
3.5. Xây dựng mô hình	14
3.5.1. Mô hình Naive Bayes	15
3.5.2. Mô hình Random Forest	15

3.6. Tích hợp mô hình vào hệ thống AI Cyber Shield.....	15
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ.....	17
4.1. Các tiêu chuẩn đánh giá	17
4.2. Kết quả thực nghiệm.....	18
4.2.1. So sánh kết quả thực nghiệm của hai mô hình	18
4.2.2. Đánh giá mức độ quan trọng của đặc trưng	19
CHƯƠNG 5. KẾT LUẬN	20
5.1 Kết quả đạt được	20
5.2 Hạn chế.....	20
5.3 Hướng phát triển.....	20

STT	Thành viên	Vai trò	Nhiệm vụ chính Giai đoạn 1(Dữ liệu & Đặc trưng)	Nhiệm vụ chính Giai đoạn 2(Mô hình & Thành phẩm)
1	Vũ Minh Hoàng	Leader	• Quản lý: Xây dựng kế hoạch dự án và phân công công việc • Nghiên cứu & Code: Nhóm 12 đặc trưng HTML & JavaScript (Nội dung trang web: <i>Favicon, Request_URL, URL_of_Anchor</i>, v.v.)	• Thực thi AI: Xử lý mất cân bằng dữ liệu (SMOTE), Huấn luyện mô hình Naive Bayes(GaussianNB) & Random Forest • Xuất file mô hình (.pkl), file kết quả dữ liệu (CSV) và các biểu đồ (Confusion Matrix, Feature Importance). • Điều phối tiến độ và tổng duyệt sản phẩm
2	Vũ Minh Tú	Thành viên	• Nghiên cứu & Code: Nhóm 12 đặc trưng Address Bar (Địa chỉ URL: <i>having_IP_Address, URL_Length, Shortening_Service</i>, v.v.)	• Phát triển Dashboard (Flask): Thiết kế giao diện (Ô nhập URL, Tab so sánh). • Tích hợp hệ thống: Nhúng hàm trích xuất đặc trưng và file model .pkl vào Web. • Visual Web: Hiện thị biểu đồ số liệu lên giao diện.
3	Ngô Đức Thắng	Thành viên	• Nghiên cứu & Code: Nhóm 5 đặc trưng Domain & Traffic (<i>age_of_domain, DNSRecord, web_traffic</i>, v.v.).	• Tài liệu & Báo cáo (Word): Viết lý thuyết thuật toán (Bayes, Random Forest, SMOTE). • Phân tích kết quả thực nghiệm, so sánh hiệu năng giữa hai mô hình. • Tổng hợp các số liệu đạt được và trình bày báo cáo
4	Vũ Tiến Thành	Thành viên	• Phát triển 3 tính năng đặc trưng riêng (<i>Typosquatting</i>,	• Thiết kế Slide: Xây dựng bộ Slide thuyết trình báo cáo (15-20 slides)

STT	Thành viên	Vai trò	Nhiệm vụ chính Giai đoạn 1(Dữ liệu & Đặc trưng)	Nhiệm vụ chính Giai đoạn 2(Mô hình & Thành phẩm)
			<i>Entropy Score, Sensitive Words</i>). • Xử lý dữ liệu thô: Chuẩn bị và trích xuất dữ liệu thô (gồm các cột url và label) • Xây dựng cấu trúc dữ liệu số: Thiết lập cấu trúc bảng số nạp vào máy để chuẩn bị cho bước chạy Naive Bayes.	dựa trên nội dung file Word. • Video Demo: Quay màn hình kịch bản sử dụng Web để dự phòng khi bảo vệ. • Hỗ trợ phản biện: Soạn thảo danh mục câu hỏi và câu trả lời phản biện tiềm năng (xoay quanh SMOTE và Random Forest).

GIỚI THIỆU ĐỀ TÀI

Trong bối cảnh Internet phát triển mạnh mẽ, các cuộc tấn công mạng ngày càng trở nên tinh vi và khó phát hiện, đặc biệt là các hình thức lừa đảo trực tuyến (phishing). Một trong những phương thức phổ biến nhất mà kẻ tấn công sử dụng là tạo ra các đường dẫn (URL) giả mạo nhằm đánh lừa người dùng truy cập vào các trang web độc hại. Những URL này thường được thiết kế rất giống với các trang web hợp pháp, khiến việc nhận diện bằng mắt thường trở nên khó khăn, từ đó gây ra nhiều rủi ro về mất mát thông tin cá nhân và tài chính.

Trước thực trạng đó, việc xây dựng các hệ thống tự động phát hiện URL độc hại trở thành một vấn đề quan trọng trong lĩnh vực an toàn thông tin. Thay vì phụ thuộc hoàn toàn vào danh sách đen (blacklist), các phương pháp học máy (machine learning) cho phép phát hiện các mẫu URL chưa từng xuất hiện trước đó thông qua việc học các đặc trưng từ dữ liệu.

Trong bài toán này, URL không thể được xử lý trực tiếp bởi các mô hình học máy, do đó cần thực hiện bước trích xuất đặc trưng để chuyển đổi URL sang dạng vector số. Các đặc trưng này có thể bao gồm thông tin về cấu trúc URL, các ký tự đặc biệt, độ dài, hoặc các thuộc tính liên quan đến miền và hành vi truy cập. Tuy nhiên, dữ liệu thực tế thường gặp vấn đề mất cân bằng giữa số lượng URL hợp lệ và URL độc hại, làm ảnh hưởng đến hiệu suất của mô hình. Vì vậy, các kỹ thuật cân bằng dữ liệu như SMOTE được áp dụng nhằm cải thiện khả năng học của mô hình.

Bên cạnh đó, việc lựa chọn và so sánh các thuật toán học máy cũng đóng vai trò quan trọng trong việc nâng cao độ chính xác của hệ thống. Trong đề tài này, thuật toán Naive Bayes được triển khai như một phương pháp phân loại cơ bản, đồng thời được so sánh với mô hình Random Forest nhằm đánh giá hiệu quả và khả năng nhận diện URL độc hại.

Mục tiêu của đề tài là xây dựng một quy trình hoàn chỉnh từ trích xuất đặc trưng, xử lý dữ liệu đến huấn luyện và đánh giá mô hình, qua đó tìm ra phương pháp phù hợp để nâng cao hiệu quả phát hiện URL độc hại trong thực tế. Kết quả của đề tài được triển khai trên ứng dụng web **AI Cyber Shield**, đóng vai trò là hệ thống ứng dụng trực quan cho phép kiểm tra và hỗ trợ phát hiện các URL có dấu hiệu lừa đảo.

CHƯƠNG 1. TỔNG QUAN HỆ THỐNG AI CYBER SHIELD


1.1. Giới thiệu hệ thống AI Cyber Shield

AI Cyber Shield là một ứng dụng web hỗ trợ phát hiện các URL có dấu hiệu lừa đảo (phishing) bằng cách ứng dụng các mô hình học máy vào quá trình phân tích và đánh giá URL. Hệ thống được xây dựng nhằm hỗ trợ người dùng nhận biết các đường dẫn độc hại trước khi truy cập, góp phần hạn chế nguy cơ đánh cắp thông tin cá nhân và tài chính trên môi trường Internet.

Khác với các phương pháp truyền thống phụ thuộc vào danh sách đen (blacklist), AI Cyber Shield có khả năng phân tích các đặc trưng của URL để nhận diện các mẫu phishing chưa từng xuất hiện trước đó. Hệ thống sử dụng các kỹ thuật trích xuất đặc trưng URL kết hợp với các mô hình học máy như Naive Bayes và Random Forest để thực hiện phân loại URL hợp lệ và URL độc hại.

Ngoài chức năng phát hiện phishing, AI Cyber Shield còn cung cấp giao diện trực quan giúp người dùng dễ dàng nhập URL, theo dõi kết quả phân tích, xem lịch sử quét và đánh giá hiệu suất mô hình. Việc triển khai mô hình dưới dạng webapp giúp tăng tính thực tiễn của đề tài và tạo ra một sản phẩm có khả năng ứng dụng trực tiếp trong thực tế.

1.2. Giao diện tổng quan của hệ thống



Hình 1.1. Giao diện tổng quan của hệ thống AI Cyber Shield

Giao diện chính của hệ thống AI Cyber Shield được thiết kế theo hướng trực quan và dễ sử dụng, cho phép người dùng thao tác nhanh chóng trong quá trình kiểm tra URL.

Tại giao diện chính, người dùng có thể nhập URL cần kiểm tra vào ô nhập dữ liệu và nhấn nút “Analyze URL” để thực hiện quá trình phân tích. Sau khi xử lý, hệ thống sẽ trả về kết quả dự đoán URL là hợp lệ hay có dấu hiệu phishing.

Ngoài chức năng quét URL, hệ thống còn cung cấp các mục chức năng như Model, History, Features và About nhằm hỗ trợ người dùng theo dõi hiệu suất mô hình cũng như hiểu rõ hơn về quá trình phân tích URL.

1.3. Các chức năng chính của hệ thống

1.3.1. Scanner

Đây là chức năng chính của hệ thống, cho phép người dùng nhập URL để thực hiện phân tích và dự đoán mức độ an toàn của đường dẫn. Hệ thống sẽ tiến hành trích xuất các đặc trưng từ URL và đưa vào mô hình học máy để thực hiện phân loại. Kết quả dự đoán được hiển thị trực tiếp trên giao diện nhằm hỗ trợ người dùng nhanh chóng nhận biết URL có dấu hiệu lừa đảo hay không.

1.3.2. Model

Mục Model Performance cho phép hiển thị các chỉ số đánh giá mô hình như Accuracy, Precision, Recall và F1-score. Đồng thời, hệ thống hỗ trợ so sánh hiệu suất giữa mô hình Naive Bayes và Random Forest nhằm xác định mô hình phù hợp cho bài toán phát hiện phishing URL.

Ngoài ra, hệ thống còn cung cấp các biểu đồ trực quan và ma trận nhầm lẫn để hỗ trợ đánh giá kết quả thực nghiệm. Thông qua các thông tin này, người dùng có thể dễ dàng theo dõi hiệu suất của từng mô hình và đánh giá khả năng phát hiện URL phishing của hệ thống.

1.3.3. History

Chức năng này lưu lại lịch sử các URL đã được kiểm tra cùng với kết quả dự đoán tương ứng. Điều này giúp người dùng dễ dàng theo dõi các lần quét trước đó và hỗ trợ quá trình kiểm tra lại khi cần thiết.

1.3.4. Feature

Feature Info cung cấp thông tin về các đặc trưng được sử dụng trong quá trình huấn luyện mô hình. Người dùng có thể tìm hiểu ý nghĩa của từng đặc trưng URL và vai trò của chúng trong việc phát hiện phishing.

1.3.5. About

Mục About cung cấp thông tin giới thiệu về hệ thống, mục tiêu phát triển và các công nghệ được sử dụng trong quá trình xây dựng ứng dụng web AI Cyber Shield.

1.4. Quy trình hoạt động của hệ thống

Quy trình hoạt động của hệ thống AI Cyber Shield được thực hiện theo các bước sau:

1. Người dùng nhập URL cần kiểm tra vào hệ thống.
2. Hệ thống tiến hành trích xuất các đặc trưng từ URL.
3. Dữ liệu đặc trưng được đưa vào mô hình học máy đã huấn luyện.
4. Mô hình thực hiện phân loại URL hợp lệ hoặc phishing.
5. Kết quả được trả về và hiển thị trên giao diện webapp.

Quy trình này giúp hệ thống có khả năng phân tích URL theo thời gian thực và hỗ trợ người dùng phát hiện các đường dẫn có dấu hiệu nguy hiểm một cách nhanh chóng.

Kết quả dự đoán của Random Forest và Naive Bayes được kết hợp để đưa ra đánh giá cuối cùng. Hệ thống phân loại URL thành ba mức độ gồm SAFE, MEDIUM RISK và HIGH RISK nhằm hỗ trợ người dùng nhận biết mức độ nguy hiểm của URL được kiểm tra.

1.5. Công nghệ và công cụ sử dụng

Hệ thống AI Cyber Shield được xây dựng bằng ngôn ngữ Python nhờ khả năng hỗ trợ mạnh mẽ cho xử lý dữ liệu, học máy và phát triển ứng dụng web. Trong quá trình phát triển hệ thống, đề tài sử dụng nhiều thư viện và công nghệ mã nguồn mở nhằm hỗ trợ các giai đoạn tiền xử lý dữ liệu, huấn luyện mô hình, trực quan hóa kết quả và triển khai hệ thống thực tế.

Thư viện Pandas được sử dụng để đọc, quản lý và xử lý tập dữ liệu URL dưới dạng DataFrame. Scikit-learn đóng vai trò là nền tảng chính để xây dựng và đánh giá các mô hình học máy như Naive Bayes và Random Forest, đồng thời hỗ trợ các độ đo đánh giá bao gồm Accuracy, Precision, Recall và F1-score.

Để giải quyết hiện tượng mất cân bằng dữ liệu giữa các lớp phishing và legitimate, đề tài sử dụng kỹ thuật SMOTE thông qua thư viện Imbalanced-learn. Ngoài ra, Matplotlib và Plotly được sử dụng để trực quan hóa dữ liệu và kết quả thực nghiệm dưới dạng biểu đồ. Thư viện Joblib hỗ trợ lưu trữ các mô hình đã huấn luyện dưới dạng file .pkl, phục vụ cho quá trình triển khai và tái sử dụng mô hình.

Trong giai đoạn trích xuất đặc trưng, hệ thống sử dụng Requests để thu thập nội dung trang web, BeautifulSoup để phân tích mã HTML và Whois để truy vấn thông tin đăng ký tên miền. Các thư viện chuẩn của Python như re, socket, urllib.parse và datetime cũng được sử dụng để xử lý URL, phân tích tên miền và xây dựng các đặc trưng phục vụ phát hiện phishing.

Ứng dụng web được phát triển trên nền tảng Flask, kết hợp HTML, CSS, JavaScript và Bootstrap 5 nhằm xây dựng giao diện trực quan, thân thiện với người dùng và hỗ trợ hiển thị trên nhiều kích thước màn hình khác nhau. Dữ liệu lịch sử quét được lưu trữ dưới dạng tệp CSV, trong khi các biểu đồ và số liệu thống kê được hiển thị thông qua thư viện Chart.js để hỗ trợ theo dõi và đánh giá kết quả nhận diện URL.

1.6. Kết luận chương

Chương này đã trình bày tổng quan về hệ thống AI Cyber Shield, bao gồm mục tiêu xây dựng, giao diện và các chức năng chính của webapp. Đồng thời, chương cũng mô tả quy trình hoạt động và các công nghệ được sử dụng trong hệ thống. Đây là cơ sở để tiếp tục trình bày các nội dung liên quan đến cơ sở lý thuyết, quá trình xây dựng mô hình và đánh giá hiệu quả hệ thống ở các chương tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về URL phishing

URL phishing là một dạng URL độc hại được sử dụng trong các cuộc tấn công lừa đảo trực tuyến nhằm dẫn người dùng đến các website giả mạo. Mục tiêu của các website này thường là đánh cắp thông tin cá nhân, tài khoản đăng nhập, dữ liệu tài chính hoặc phát tán mã độc. Trong thực tế, các URL phishing thường được thiết kế có hình thức tương tự với các website hợp lệ nhằm tạo sự tin tưởng và đánh lừa người dùng truy cập.

Một trong những đặc điểm phổ biến của URL phishing là cấu trúc bất thường hoặc cố tình gây nhầm lẫn. Kẻ tấn công có thể sử dụng các tên miền gần giống với tên miền thật, thêm nhiều ký tự đặc biệt, sử dụng nhiều subdomain hoặc kéo dài chuỗi URL để che giấu domain chính. Ngoài ra, một số URL phishing còn sử dụng địa chỉ IP thay cho tên miền hoặc chèn các từ khóa quen thuộc như “login”, “verify”, “bank”, “secure” nhằm làm tăng mức độ tin cậy đối với người dùng.

So với việc phân tích toàn bộ nội dung website, việc phát hiện phishing dựa trên URL có ưu điểm là tốc độ xử lý nhanh và không cần truy cập trực tiếp vào trang web, từ đó giúp giảm nguy cơ tiếp xúc với mã độc hoặc nội dung nguy hiểm. Vì vậy, nhiều hệ thống phát hiện phishing hiện nay tập trung vào việc phân tích các đặc trưng của chuỗi URL để nhận diện các dấu hiệu bất thường.

Trong các nghiên cứu về phát hiện URL phishing, URL thường được chuyển đổi thành tập các đặc trưng số học hoặc nhị phân để phục vụ cho quá trình huấn luyện mô hình học máy. Một số đặc trưng phổ biến bao gồm độ dài URL, số lượng dấu chấm, số lượng subdomain, sự xuất hiện của ký tự đặc biệt, giao thức HTTPS, tuổi domain và mức độ phổ biến của website. Dựa trên các đặc trưng này, các thuật toán học máy có thể học được sự khác biệt giữa URL hợp lệ và URL phishing nhằm thực hiện phân loại tự động.

2.2. Thuật toán Naive Bayes

Thuật toán Naive Bayes là một phương pháp phân loại xác suất phổ biến trong học máy, thường được sử dụng trong các bài toán phân loại dữ liệu có số chiều lớn như phân loại văn bản hay phát hiện URL phishing. Thuật toán thuộc nhóm mô hình sinh (Generative Model), trong đó mục tiêu là ước lượng xác suất dữ liệu thuộc về từng lớp để đưa ra kết quả phân loại. Mặc dù sử dụng giả định đơn giản về tính độc lập giữa các đặc trưng, Naive Bayes vẫn cho hiệu quả tốt trong nhiều bài toán thực tế và thường được sử dụng làm mô hình cơ sở để so sánh với các phương pháp khác.

Nền tảng toán học của Naive Bayes dựa trên định lý Bayes, một định lý quan trọng trong xác suất thống kê cho phép tính toán xác suất hậu nghiệm của một biến ngẫu nhiên dựa trên các thông tin quan sát được. Theo định lý Bayes, xác suất một mẫu dữ liệu X thuộc lớp y được xác định thông qua mối quan hệ giữa xác suất tiên nghiệm của lớp và xác suất quan sát dữ liệu khi biết lớp đó. Công thức của định lý Bayes được biểu diễn như sau:

$$P(y | X) = \frac{P(X | y) P(y)}{P(X)}$$

Trong đó, $P(y|X)$ là xác suất hậu nghiệm, thể hiện khả năng mẫu dữ liệu X thuộc lớp y sau khi đã quan sát dữ liệu; $P(y)$ là xác suất tiên nghiệm của lớp; $P(X|y)$ là xác suất có điều kiện của dữ liệu đầu vào khi biết lớp; và $P(X)$ là xác suất của dữ liệu quan sát, đóng vai trò chuẩn hóa.

Trong bài toán phân loại, mục tiêu là tìm lớp có xác suất hậu nghiệm lớn nhất. Tuy nhiên, việc tính trực tiếp $P(X | y)$ rất phức tạp khi số lượng đặc trưng lớn. Vì vậy, Naive Bayes đưa ra giả định rằng các đặc trưng độc lập có điều kiện với nhau khi biết lớp cần phân loại:

$$P(X | y) = \prod_{i=1}^n P(x_i | y)$$

Từ đó, quy tắc phân loại của Naive Bayes được suy ra bằng cách thay biểu thức trên vào định lý Bayes và loại bỏ hằng số không phụ thuộc vào lớp, dẫn đến công thức quyết định:

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(x_i | y)$$

Trong đề tài phát hiện URL phishing, mỗi URL được biểu diễn dưới dạng một vector đặc trưng gồm các thông tin như độ dài URL, số lượng subdomain, trạng thái HTTPS, mức độ phổ biến của domain hoặc sự xuất hiện của các ký tự đặc biệt. Dựa trên các đặc trưng này, mô hình sẽ tính xác suất URL thuộc lớp phishing hoặc legitimate và đưa ra kết quả phân loại.

Naive Bayes có ưu điểm về tốc độ huấn luyện nhanh, cấu trúc đơn giản và khả năng xử lý tốt dữ liệu nhiều đặc trưng. Mặc dù giả định độc lập giữa các đặc trưng không hoàn toàn đúng trong thực tế, thuật toán vẫn cho hiệu quả tốt trong bài toán phát hiện URL phishing và phù hợp làm mô hình cơ sở để so sánh với các phương pháp khác như Random Forest.

2.3. Thuật toán Random Forest

Random Forest là một thuật toán học máy thuộc nhóm phương pháp học tổ hợp (ensemble learning), được xây dựng dựa trên việc kết hợp nhiều cây quyết định (decision trees) nhằm nâng cao độ chính xác và khả năng tổng quát hóa của mô hình. Ý tưởng cốt lõi của Random Forest là thay vì sử dụng một cây quyết định đơn lẻ, mô hình sẽ tạo ra một “rừng” gồm nhiều cây, trong đó mỗi cây được huấn luyện trên các tập dữ liệu con khác nhau và đưa ra dự đoán độc lập. Kết quả cuối cùng được xác định thông qua cơ chế bỏ phiếu đa số đối với bài toán phân loại.

Quá trình xây dựng Random Forest dựa trên hai kỹ thuật quan trọng là *bagging* (Bootstrap Aggregating) và lựa chọn ngẫu nhiên tập đặc trưng. Cụ thể, từ tập dữ liệu ban đầu, nhiều tập con được tạo ra bằng cách lấy mẫu có hoàn lại. Mỗi tập con này được sử dụng để huấn luyện một cây quyết định riêng biệt. Đồng thời, tại mỗi nút của cây, chỉ một tập con ngẫu nhiên các đặc trưng được xem xét để tìm phép tách tốt nhất, thay vì sử dụng toàn bộ đặc trưng. Điều này giúp giảm sự tương quan giữa các cây và làm tăng tính đa dạng của mô hình.

Về mặt toán học, giả sử có T cây quyết định, mỗi cây đưa ra dự đoán $h_t(X)$ cho một mẫu dữ liệu X . Khi đó, kết quả phân loại của Random Forest được xác định thông qua cơ chế bỏ phiếu:

$$\hat{y} = \text{mode}\{h_1(X), h_2(X), \dots, h_T(X)\}$$

Trong bài toán phát hiện URL phishing, Random Forest có khả năng khai thác các mối quan hệ phi tuyến và sự tương tác giữa các đặc trưng của URL, chẳng hạn như mối liên hệ giữa độ dài URL, số lượng ký tự đặc biệt và cấu trúc domain. Điều này giúp mô hình có thể đạt độ chính xác cao hơn so với các phương pháp đơn giản như Naive Bayes, đặc biệt trong trường hợp các đặc trưng không độc lập.

Tuy nhiên, Random Forest cũng có một số hạn chế như chi phí tính toán cao hơn, thời gian huấn luyện dài hơn và khó diễn giải kết quả so với các mô hình xác suất. Do đó, trong đề tài này, Random Forest được sử dụng như một mô hình so sánh nhằm đánh giá hiệu quả của Naive Bayes, từ đó làm nổi bật ưu điểm về tốc độ và tính đơn giản của mô hình chính.

2.4. Kỹ thuật SMOTE

SMOTE (Synthetic Minority Over-sampling Technique) là kỹ thuật cân bằng dữ liệu thường được sử dụng trong các bài toán phân loại khi số lượng mẫu giữa các lớp có sự chênh lệch lớn. Trong bài toán

phát hiện URL phishing, số lượng URL phishing thường ít hơn nhiều so với URL hợp lệ, khiến mô hình dễ thiên lệch về lớp đa số.

Khác với phương pháp sao chép dữ liệu thông thường, SMOTE tạo ra các mẫu dữ liệu mới cho lớp thiểu số bằng phương pháp nội suy giữa các điểm dữ liệu gần nhau trong không gian đặc trưng. Cụ thể, với một mẫu x_i , thuật toán chọn một láng giềng gần nhất x_{zi} và sinh mẫu mới theo công thức:

$$x_{\text{new}} = x_i + \lambda \cdot (x_{zi} - x_i)$$

trong đó λ là một số ngẫu nhiên trong khoảng $[0,1]$. Công thức này cho phép tạo ra các điểm dữ liệu mới nằm giữa các mẫu hiện có, từ đó mở rộng không gian phân bố của lớp thiểu số một cách tự nhiên hơn so với việc lặp lại dữ liệu.

Việc sử dụng SMOTE giúp cải thiện đáng kể khả năng học của mô hình đối với lớp thiểu số, đồng thời giảm hiện tượng overfitting do trùng lặp dữ liệu. Tuy nhiên, do các mẫu được tạo ra dựa trên nội suy tuyến tính, SMOTE có thể làm mờ ranh giới giữa các lớp nếu dữ liệu ban đầu có sự chồng lấn hoặc chứa nhiễu.

Trong đề tài phát hiện URL phishing, SMOTE được áp dụng sau bước trích xuất đặc trưng nhằm cân bằng số lượng giữa các URL hợp lệ và URL lừa đảo. Điều này giúp các mô hình như Naive Bayes và Random Forest có thể học được đặc trưng của lớp phishing một cách đầy đủ hơn, từ đó nâng cao độ chính xác và khả năng nhận diện các URL độc hại.

CHƯƠNG 3. PHÂN TÍCH VÀ XÂY DỰNG HỆ THỐNG

3.1. Tập dữ liệu

Trong đề tài, dữ liệu được thu thập từ hai nguồn chính gồm bộ dữ liệu phishing trên Mendeley Data và bộ dữ liệu URL độc hại trên Kaggle. Bộ dữ liệu Mendeley gồm 11.430 URL với 87 đặc trưng đã được trích xuất sẵn, bao gồm các đặc trưng về cấu trúc URL, nội dung website và thông tin từ dịch vụ bên ngoài. Bộ dữ liệu này được cân bằng với tỷ lệ 50% URL phishing và 50% URL hợp lệ. Bộ dữ liệu Kaggle gồm 651.191 URL thuộc nhiều loại khác nhau như benign, phishing, malware và defacement trong đó số lượng URL an toàn(benign) là 428.103.

Từ các nguồn dữ liệu ban đầu, đề tài tiến hành lọc, trích xuất đặc trưng và xử lý dữ liệu để tạo tập dữ liệu huấn luyện cuối cùng traintdata.csv gồm 41.536 URL, trong đó tỷ lệ URL phishing chiếm khoảng 19,19% trước khi thực hiện SMOTE.

3.2. Tiền xử lý dữ liệu

Tập dữ liệu sử dụng trong đề tài bao gồm các URL cùng với các đặc trưng được trích xuất dựa trên cấu trúc và hành vi của URL. Mỗi đặc trưng được mã hóa theo ba mức giá trị gồm:

Giá trị (1): đặc trưng hợp lệ hoặc an toàn.

Giá trị (0): trạng thái trung lập.

Giá trị (-1): đặc trưng có dấu hiệu đáng ngờ hoặc phishing.

Đối với nhãn phân loại, tập dữ liệu gồm hai lớp: URL hợp lệ (1) và URL phishing (-1). Trong quá trình huấn luyện, nhãn (-1) được chuyển đổi thành (0) để phù hợp với các thư viện học máy trong Python. Sau đó, dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo tỉ lệ 80:20 bằng phương pháp train-test split.

Do dữ liệu tồn tại hiện tượng mất cân bằng giữa số lượng URL hợp lệ và URL phishing, kỹ thuật SMOTE được áp dụng trên tập huấn luyện nhằm sinh thêm dữ liệu cho lớp thiểu số, giúp mô hình học hiệu quả hơn. Sau bước tiền xử lý, dữ liệu được biểu diễn dưới dạng vector đặc trưng và được sử dụng làm đầu vào cho các mô hình Naive Bayes và Random Forest.

3.3. Trích xuất đặc trưng URL

Trong đề tài, các đặc trưng URL được trích xuất bằng Python thông qua việc phân tích cấu trúc URL, thông tin domain, mã HTML và hành vi của website. Quá trình này sử dụng các thư viện như re, urllib.parse, requests, BeautifulSoup, socket và whois. Sau khi phân tích, mỗi URL được biểu diễn dưới dạng vector đặc trưng phục vụ cho quá trình huấn luyện mô hình học máy.

3.3.1 Nhóm đặc trưng dựa trên cấu trúc URL

Nhóm đặc trưng này tập trung phân tích cấu trúc chuỗi URL nhằm phát hiện các dấu hiệu bất thường thường xuất hiện trong các URL phishing. Các đặc trưng được sử dụng bao gồm việc kiểm tra sự xuất hiện của địa chỉ IP thay cho tên miền, độ dài URL, dịch vụ rút gọn liên kết, ký tự đặc biệt, số lượng subdomain, các dấu hiệu bất thường trong tên miền và cổng mạng sử dụng. Ngoài ra, nghiên cứu còn bổ sung hai đặc trưng là URL_Entropy và Sensitive_Word_Count nhằm nâng cao khả năng nhận diện các URL đáng ngờ.

Đặc trưng URL_Entropy được xây dựng dựa trên công thức Shannon Entropy nhằm đo lường mức độ ngẫu nhiên của chuỗi ký tự trong URL. Các URL phishing được sinh tự động hoặc sử dụng chuỗi ký tự khó nhận biết thường có giá trị entropy cao hơn so với các URL hợp lệ.

Đặc trưng Sensitive_Word_Count được sử dụng để đếm số lượng từ khóa nhạy cảm thường xuất hiện trong các chiến dịch lừa đảo như login, verify, account, password, banking, payment, update, confirm, momo, vnpay và vietcombank. Sự xuất hiện đồng thời của nhiều từ khóa này có thể là dấu hiệu cho thấy website đang cố gắng đánh lừa người dùng cung cấp thông tin cá nhân hoặc thông tin tài chính.

3.3.2 Nhóm đặc trưng liên quan đến domain và bảo mật

Nhóm đặc trưng này khai thác các thông tin liên quan đến tên miền và mức độ tin cậy của website, bao gồm trạng thái HTTPS, thời gian đăng ký và tuổi domain, DNS record, khả năng được Google lập chỉ mục, thông tin blacklist, mức độ phổ biến của website và khả năng giả mạo tên miền.

Trong đó, đặc trưng Web_Traffic được xây dựng bằng cách đối chiếu domain với danh sách 10.000 website phổ biến được thu thập từ Cloudflare Radar nhằm hỗ trợ đánh giá mức độ uy tín của website. Việc lựa chọn 10.000 domain giúp cân bằng giữa độ bao phủ dữ liệu và khả năng phân biệt URL phishing với URL hợp lệ.

Bên cạnh đó, đặc trưng Typosquatting_Score được sử dụng để phát hiện các tên miền giả mạo thương hiệu. Đặc trưng này dựa trên khoảng cách chỉnh sửa Levenshtein kết hợp với kỹ thuật chuẩn hóa các ký tự dễ gây nhầm lẫn nhằm đánh giá mức độ tương đồng giữa tên miền cần kiểm tra và các tên miền phổ biến, từ đó hỗ trợ phát hiện các URL có dấu hiệu giả mạo.

3.3.3 Nhóm đặc trưng dựa trên mã HTML và hành vi website

Đối với nhóm đặc trưng này, hệ thống gửi HTTP request tới website và phân tích mã HTML bằng thư viện BeautifulSoup nhằm phát hiện các hành vi đáng ngờ. Các đặc trưng được sử dụng tập trung vào việc phân tích favicon, liên kết ngoài domain, biểu mẫu nhập liệu, cơ chế chuyển hướng, iframe, popup window và các đoạn mã JavaScript có khả năng tác động đến hành vi của người dùng.

Nhìn chung, các đặc trưng trong đề tài được xây dựng dựa trên việc phân tích cấu trúc URL, thông tin domain, mã HTML và hành vi website nhằm cung cấp cho mô hình học máy những thông tin cần thiết để phát hiện URL phishing một cách hiệu quả.

3.4. Biểu diễn URL dưới dạng vector đặc trưng

Sau khi trích xuất đặc trưng, mỗi URL sẽ được chuyển đổi thành một vector số học để phục vụ cho quá trình huấn luyện mô hình học máy. Trong đề tài, mỗi URL được biểu diễn thông qua 32 đặc trưng liên quan đến cấu trúc URL, thông tin domain và hành vi của website.

Mỗi đặc trưng được mã hóa theo ba giá trị: -1, 0, 1 như đã đề cập trong mục 2.3. Sau khi mã hóa, URL được biểu diễn dưới dạng vector:

$$[X] = [x_1, x_2, x_3, \dots, x_{32}]$$

Trong đó mỗi phần tử x_i tương ứng với một đặc trưng đã được trích xuất.

Việc biểu diễn URL dưới dạng vector đặc trưng giúp chuyển đổi dữ liệu từ dạng chuỗi ký tự sang dữ liệu số học có cấu trúc, tạo điều kiện cho các thuật toán học máy như Naive Bayes và Random Forest thực hiện quá trình phân loại URL phishing.

3.5. Xây dựng mô hình

Sau khi dữ liệu được tiền xử lý và biểu diễn dưới dạng vector đặc trưng, đề tài tiến hành xây dựng và huấn luyện các mô hình học máy nhằm phân loại URL thành hai nhóm gồm URL hợp lệ và URL phishing. Trong đề tài, hai thuật toán được sử dụng gồm Naive Bayes và Random Forest.

3.5.1. Mô hình Naive Bayes

Naive Bayes là thuật toán học máy dựa trên định lý Bayes với giả thiết các đặc trưng độc lập có điều kiện với nhau. Trong đề tài, mô hình Gaussian Naive Bayes (GaussianNB) được lựa chọn do dữ liệu đầu vào đã được biểu diễn dưới dạng các giá trị số học.

Quá trình huấn luyện mô hình được thực hiện trên tập dữ liệu huấn luyện sau khi áp dụng kỹ thuật SMOTE để cân bằng dữ liệu. Mô hình học mối quan hệ giữa các đặc trưng URL và nhãn phân loại nhằm xác định xác suất một URL thuộc lớp phishing hoặc hợp lệ.

Sau khi huấn luyện hoàn tất, mô hình được sử dụng để dự đoán nhãn cho tập dữ liệu kiểm tra. Kết quả dự đoán sau đó được sử dụng để đánh giá hiệu năng của mô hình thông qua các độ đo như Accuracy, Precision, Recall và F1-score.

3.5.2. Mô hình Random Forest

Random Forest là thuật toán học máy thuộc nhóm Ensemble Learning, hoạt động dựa trên việc kết hợp nhiều cây quyết định để đưa ra kết quả phân loại cuối cùng. Thuật toán này giúp giảm hiện tượng overfitting và cải thiện độ chính xác so với một cây quyết định đơn lẻ.

Trong đề tài, mô hình Random Forest được xây dựng với 100 cây quyết định ($n_estimators = 100$). Mỗi cây được huấn luyện trên một tập mẫu ngẫu nhiên của dữ liệu huấn luyện, đồng thời chỉ sử dụng một phần ngẫu nhiên các đặc trưng trong quá trình phân chia nút.

Sau quá trình huấn luyện, kết quả phân loại cuối cùng được xác định dựa trên cơ chế bỏ phiếu đa số giữa các cây quyết định. Mô hình sau đó được sử dụng để dự đoán nhãn của tập dữ liệu kiểm tra nhằm đánh giá hiệu năng phân loại URL phishing.

Ngoài khả năng phân loại, Random Forest còn hỗ trợ đánh giá mức độ quan trọng của từng đặc trưng thông qua thuộc tính `feature_importances_`. Điều này giúp xác định các đặc trưng có ảnh hưởng lớn nhất đến quá trình phát hiện URL phishing.

3.6. Tích hợp mô hình vào hệ thống AI Cyber Shield

Sau khi hoàn thành quá trình huấn luyện và đánh giá, các mô hình Random Forest và Naive Bayes được lưu dưới dạng file .pkl để phục vụ triển khai trong hệ thống AI Cyber Shield.

Khi người dùng nhập một URL, hệ thống sẽ thực hiện trích xuất đặc trưng thông qua lớp URLFeatureExtractor. Các đặc trưng thu được được chuyển đổi thành vector đầu vào phù hợp với cấu trúc dữ liệu đã sử dụng trong quá trình huấn luyện mô hình. Sau đó, hai mô hình Random Forest và Naive Bayes được sử dụng để tính toán xác suất URL thuộc lớp phishing thông qua hàm `predict_proba()`.

Xác suất phishing do mỗi mô hình trả về được chuyển đổi thành chỉ số Risk Score theo đơn vị phần trăm để hiển thị cho người dùng. Hệ thống sử dụng ngưỡng phân loại 50%, nghĩa là nếu Risk Score lớn hơn hoặc bằng 50% thì URL được mô hình tương ứng đánh giá là phishing, ngược lại được xem là hợp lệ.

Để nâng cao độ tin cậy của kết quả, AI Cyber Shield áp dụng cơ chế kết hợp hai mô hình. Nếu cả Random Forest và Naive Bayes đều dự đoán phishing, hệ thống đưa ra cảnh báo HIGH RISK. Nếu chỉ một trong hai mô hình phát hiện dấu hiệu phishing, kết quả được đánh giá là MEDIUM RISK. Trường hợp cả hai mô hình đều đánh giá URL an toàn, hệ thống trả về kết quả SAFE.

Ngoài chức năng phát hiện phishing, hệ thống còn lưu lại lịch sử quét URL cùng các thông tin liên quan để phục vụ việc theo dõi, thống kê và đánh giá hoạt động của mô hình. Thông qua quá trình tích

hợp này, AI Cyber Shield đã hoàn thiện quy trình từ nhập URL, trích xuất đặc trưng, dự đoán đến hiển thị kết quả cho người dùng.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Các tiêu chuẩn đánh giá

Để đánh giá hiệu quả của các mô hình học máy trong bài toán phát hiện URL phishing, đề tài sử dụng các độ đo phổ biến trong phân loại dữ liệu gồm Confusion Matrix, Accuracy, Precision, Recall và F1-Score. Các chỉ số này giúp đánh giá khả năng phân loại của mô hình đối với cả URL hợp lệ và URL phishing.

Confusion Matrix là ma trận nhầm lẫn dùng để mô tả kết quả phân loại của mô hình thông qua số lượng dự đoán đúng và sai giữa các lớp dữ liệu.

Ma trận bao gồm bốn thành phần:

True Positive (TP): URL phishing được phát hiện đúng.

True Negative (TN): URL hợp lệ được phân loại đúng.

False Positive (FP): URL hợp lệ bị nhận nhầm là phishing.

False Negative (FN): URL phishing không được phát hiện.

Thông qua Confusion Matrix, có thể đánh giá chi tiết khả năng phân loại của mô hình cũng như xác định các loại lỗi mà mô hình thường gặp trong quá trình phát hiện URL phishing.

Accuracy là độ chính xác tổng thể của mô hình, phản ánh tỷ lệ dự đoán đúng trên tổng số mẫu dữ liệu. Công thức tính Accuracy:

Giá trị Accuracy càng cao thì mô hình có độ chính xác tổng thể càng tốt. Tuy nhiên, đối với dữ liệu mất cân bằng, Accuracy chưa phản ánh đầy đủ khả năng phát hiện phishing của mô hình.

Precision phản ánh mức độ chính xác của các URL được mô hình dự đoán là phishing. Công thức tính Precision:

Precision cao cho thấy số lượng cảnh báo nhầm thấp, tức mô hình ít nhận nhầm URL hợp lệ thành phishing.

Recall phản ánh khả năng phát hiện các URL phishing thực tế của mô hình. Công thức tính Recall:

Recall càng cao thì mô hình càng phát hiện được nhiều URL phishing và giảm nguy cơ bỏ sót website độc hại.


F1-Score là giá trị trung bình điều hòa giữa Precision và Recall, giúp đánh giá tổng quát hiệu năng mô hình trên dữ liệu mất cân bằng. Công thức tính F1-Score:

Giá trị F1-Score càng cao thì mô hình càng có sự cân bằng tốt giữa độ chính xác và khả năng phát hiện phishing.

4.2. Kết quả thực nghiệm

4.2.1. So sánh kết quả thực nghiệm của hai mô hình

Ma trận nhầm lẫn



Bảng so sánh các độ đo

Thuật toán	Accuracy	Precision	Recall	F1-Score
Naive Bayes	0.847617	0.933173	0.872353	0.901739
Random Forest	0.932715	0.975532	0.939631	0.95724

Kết quả thực nghiệm cho thấy cả hai mô hình Naive Bayes và Random Forest đều có khả năng phân loại URL phishing tương đối hiệu quả sau khi áp dụng kỹ thuật cân bằng dữ liệu SMOTE. Tuy nhiên, mô hình Random Forest cho kết quả vượt trội hơn so với Naive Bayes ở tất cả các tiêu chuẩn đánh giá.

Đối với mô hình Naive Bayes, Accuracy đạt khoảng 84,76%, Precision đạt 93,32%, Recall đạt 87,24% và F1-Score đạt 90,17%. Kết quả này cho thấy mô hình có khả năng phân loại tương đối tốt và số lượng cảnh báo nhầm không quá cao. Tuy nhiên, thông qua Confusion Matrix có thể nhận thấy mô hình vẫn bỏ sót khá nhiều URL phishing khi có tới 416 URL độc hại bị phân loại nhầm thành URL an toàn. Ngoài ra, mô hình cũng nhận nhầm 850 URL an toàn thành phishing. Điều này cho thấy giả thiết độc lập giữa các đặc trưng của Naive Bayes chưa thực sự phù hợp với bài toán URL phishing, do trong thực tế nhiều đặc trưng có mối liên hệ với nhau.

Trong khi đó, mô hình Random Forest đạt Accuracy khoảng 93,27%, Precision đạt 97,55%, Recall đạt 93,96% và F1-Score đạt 95,72%, cao hơn đáng kể so với Naive Bayes. Kết quả Confusion Matrix cho thấy mô hình giảm mạnh số lượng dự đoán sai, chỉ còn 157 URL phishing bị bỏ sót và 402 URL an toàn bị nhận nhầm là phishing. Điều này cho thấy Random Forest có khả năng học tốt hơn các đặc trưng phức tạp của URL nhờ cơ chế kết hợp nhiều cây quyết định.


Bên cạnh đó, Precision cao của Random Forest cho thấy mô hình có độ tin cậy lớn khi đưa ra cảnh báo phishing, giúp giảm số lượng cảnh báo giả đối với người dùng. Recall cũng đạt giá trị cao, chứng tỏ mô hình phát hiện được phần lớn các URL phishing trong tập dữ liệu.

Từ kết quả thực nghiệm có thể thấy Random Forest là mô hình phù hợp hơn đối với bài toán phát hiện URL phishing nhờ khả năng phân loại chính xác và ổn định hơn. Tuy nhiên, Naive Bayes vẫn có ưu

điểm về tốc độ huấn luyện nhanh, cấu trúc đơn giản và chi phí tính toán thấp, phù hợp với các hệ thống yêu cầu xử lý nhanh hoặc tài nguyên hạn chế.

4.2.2. Đánh giá mức độ quan trọng của đặc trưng

Đề tài sử dụng thuộc tính `feature_importances_` của mô hình Random Forest để đánh giá mức độ ảnh hưởng của từng đặc trưng đối với quá trình phân loại URL phishing.



Kết quả thực nghiệm cho thấy các đặc trưng như `dns_record`, `google_index`, `right_click`, `url_entropy`, `port`, `submit_email` có mức độ ảnh hưởng cao nhất đến mô hình. Điều này cho thấy các yếu tố liên quan đến thông tin domain, trạng thái bảo mật và cấu trúc URL đóng vai trò quan trọng trong việc phát hiện phishing.

Ngoài ra, các đặc trưng như `SSLfinal_State`, `sensitive_word_count`, `URL_length`, `right_click`, `web_traffic` cũng góp phần hỗ trợ quá trình phân loại. Kết quả Feature Importance cho thấy tập đặc trưng được lựa chọn có khả năng phản ánh tốt đặc điểm của URL phishing và hỗ trợ hiệu quả cho mô hình Random Forest trong quá trình học và phân loại dữ liệu.

CHƯƠNG 5. KẾT LUẬN

5.1 Kết quả đạt được

Trong phạm vi đề tài, hệ thống phát hiện URL phishing đã được xây dựng và triển khai thành công trên nền tảng webapp AI Cyber Shield. Đề tài đã thực hiện quá trình thu thập và xử lý dữ liệu, xây dựng tập đặc trưng dựa trên cấu trúc URL, thông tin domain và hành vi của website nhằm phục vụ cho bài toán phân loại URL hợp lệ và URL phishing.

Bên cạnh đó, kỹ thuật SMOTE đã được áp dụng để xử lý hiện tượng mất cân bằng dữ liệu, góp phần nâng cao khả năng học của mô hình đối với lớp phishing. Hai thuật toán học máy là Naive Bayes và Random Forest đã được huấn luyện, đánh giá và so sánh thông qua các độ đo Accuracy, Precision, Recall và F1-score. Kết quả thực nghiệm cho thấy mô hình Random Forest đạt hiệu quả phân loại cao hơn, trong khi Naive Bayes vẫn thể hiện ưu điểm về tốc độ xử lý và độ đơn giản trong triển khai.

Ngoài việc xây dựng mô hình, đề tài còn triển khai thành công hệ thống AI Cyber Shield, cho phép người dùng nhập URL, thực hiện phân tích tự động và nhận kết quả dự đoán thông qua giao diện trực quan. Điều này góp phần nâng cao tính ứng dụng thực tế của đề tài trong hỗ trợ phát hiện các đường dẫn có dấu hiệu lừa đảo.

5.2 Hạn chế

Mặc dù đạt được những kết quả khả quan, đề tài vẫn còn một số hạn chế nhất định. Thứ nhất, tập đặc trưng được xây dựng chủ yếu dựa trên các phương pháp trích xuất thủ công nên chưa phản ánh đầy đủ các đặc điểm phức tạp của các cuộc tấn công phishing hiện đại. Thứ hai, mặc dù dữ liệu đã được xử lý và cân bằng bằng SMOTE, quy mô tập dữ liệu vẫn còn hạn chế so với sự đa dạng của các URL xuất hiện trong thực tế.

Ngoài ra, đề tài chỉ tập trung vào các thuật toán học máy truyền thống như Naive Bayes và Random Forest mà chưa nghiên cứu các phương pháp học sâu (Deep Learning) hoặc các mô hình hiện đại có khả năng khai thác tốt hơn thông tin ngữ nghĩa từ chuỗi URL. Một số đặc trưng phụ thuộc vào dịch vụ bên ngoài như WHOIS hoặc DNS cũng có thể ảnh hưởng đến tốc độ xử lý và tính ổn định của hệ thống.

5.3 Hướng phát triển

Trong tương lai, hệ thống có thể được mở rộng theo nhiều hướng nhằm nâng cao hiệu quả phát hiện URL phishing. Trước hết, có thể nghiên cứu và thử nghiệm các mô hình mạnh hơn như XGBoost, LightGBM hoặc các phương pháp học sâu để cải thiện độ chính xác của quá trình phân loại.

Bên cạnh đó, việc áp dụng các kỹ thuật xử lý ngôn ngữ tự nhiên (NLP) trên chuỗi URL có thể giúp mô hình tự động học được các đặc trưng quan trọng mà không cần phụ thuộc hoàn toàn vào quá trình trích xuất thủ công. Đồng thời, tập dữ liệu cũng cần được mở rộng và cập nhật thường xuyên nhằm phản ánh tốt hơn các xu hướng phishing mới xuất hiện trên Internet.

Ngoài ra, hệ thống AI Cyber Shield có thể được phát triển theo hướng phát hiện thời gian thực thông qua việc tích hợp với trình duyệt web hoặc tiện ích mở rộng (browser extension), từ đó hỗ trợ người dùng nhận diện và cảnh báo các URL độc hại ngay trong quá trình truy cập.